

Отчет по eval-прогонам

Методология оценок: [exports/pdf/methodology/scoring_methodology.pdf](#).

Формат отчета: цели берутся из БД, колонки раундов строятся нарастающим итогом по таблице **eval_runs**.

Декомпозиция требований в импортированных Excel-раундах не передавалась, поэтому ее критерии пока не измерялись.

Параметры прогонов

Раунд	Run code	ТК	Что изменили	Агент	Модель	Temperature	Top P	Режим
1	v0	24	Тестовый демо-прогон v0: человекочитаемый экспорт ТК, без полных данных об агенте, промпте и декомпозиции.	text_demo v0	v0	0.0	1.0	direct_extraction
2	v1	51	Раунд v1: импорт из output_v1.xlsx, 51 сгенерированный ТК из папки prompts_v1.	prompts_v1 v1	v1	0.0	1.0	direct_extraction
3	v2	35	Раунд v2: импорт из output_v2.xlsx, набор сокращен и структурирован относительно v1.	prompts_v2 v2	v2	0.0	1.0	direct_extraction

1. Декомпозиция требований

Критерий	Цель	Baseline	Раунд 1	Раунд 2	Раунд 3
Полнота декомпозиции	100%	—	—	—	—
Границы требований	100%	—	—	—	—
Консолидация требований	100%	—	—	—	—

Вывод по блоку декомпозиции

В текущих раундах на вход отчета передавались только сгенерированные тест-кейсы. Результат декомпозиции требований от агента не импортировался, поэтому критерии **decomposition_completeness**, **decomposition_boundaries** и **requirement_consolidation** пока не измерялись.

2. Набор ТК

Критерий	Цель	Baseline	Раунд 1	Раунд 2	Раунд 3
Позитивное покрытие	100%	—	7.0/10	9.3/10	8.2/10
Негативное покрытие	100%	—	6.0/10	10.0/10	9.0/10
Чистота набора	0 лишних	—	4.0/10	3.6/10	7.0/10
Покрытие обязательных проверок	100%	—	6.5/10	10.0/10	9.6/10
Общая полнота набора	100%	—	6.0/10	7.5/10	8.5/10

Вывод по блоку набора ТК

Раунд	Критерий	Score	Почему такая оценка
1	Позитивное покрытие	7.0/10	Позитивные сценарии покрывают значимую часть эталона, но нет явного покрытия size/page, одного контура и полноценного E2E-сценария.
1	Негативное покрытие	6.0/10	Есть негативные UI/API проверки, но часть негативов производная или не подтверждена ТЗ.
1	Чистота набора	4.0/10	Набор раздроблен на 24 одношаговых ТК, есть дубли UI/API и проверки вне явно заданных endpoint в ТЗ.
1	Покрытие обязательных проверок	6.5/10	Часть обязательных проверок покрыта, но отсутствуют или слабо покрыты size/page, контурность, полноценная трассировка и часть эталонных комплексных сценариев.
1	Общая полнота набора	6.0/10	Набор демонстрирует основную возможность генерации ТК, но требует ручной чистки, объединения дублей и проверки трассировки.
2	Позитивное покрытие	9.3/10	Позитивные ТК покрывают 26 из 28 эталонных требований MVP.
2	Негативное покрытие	10.0/10	Негативные ТК покрывают 10 из 10 требований, где негативные проверки применимы.
2	Чистота набора	3.6/10	В наборе 51 ТК; 14 ТК имеют заметный риск неподтвержденных деталей.
2	Покрытие обязательных проверок	10.0/10	Эвристическая трассировка нашла покрытие 28 из 28 обязательных требований.
2	Общая полнота набора	7.5/10	Итог учитывает позитивное/негативное покрытие, обязательные проверки и чистоту набора.
3	Позитивное покрытие	8.2/10	Позитивные ТК покрывают 23 из 28 эталонных требований MVP.
3	Негативное покрытие	9.0/10	Негативные ТК покрывают 9 из 10 требований, где негативные проверки применимы.

Раунд	Критерий	Score	Почему такая оценка
3	Чистота набора	7.0/10	В наборе 35 ТК; 2 ТК имеют заметный риск неподтвержденных деталей.
3	Покрытие обязательных проверок	9.6/10	Эвристическая трассировка нашла покрытие 27 из 28 обязательных требований.
3	Общая полнота набора	8.5/10	Итог учитывает позитивное/негативное покрытие, обязательные проверки и чистоту набора.

3. Отдельные ТК

Критерий	Цель	Baseline	Раунд 1	Раунд 2	Раунд 3
Корректность вида ТК	≥0,9	—	9.9/10	9.8/10	9.8/10
Шаблон и обязательные атрибуты	100%	—	5.0/10	7.5/10	7.9/10
Предусловия и постусловия	≥0,9	—	8.0/10	8.2/10	8.2/10
Атомарность шагов	≥0,9	—	9.0/10	9.4/10	9.3/10
Ожидаемый результат	≥0,9	—	8.5/10	8.6/10	8.6/10
Достоверность	галлюцинаций 0	—	7.6/10	8.6/10	9.8/10

Вывод по блоку отдельных ТК

Раунд	Критерий	Score	Почему такая оценка
1	Корректность вида ТК	9.9/10	Среднее по 24 ТК: типы в основном совпадают с названиями/метками; снижение связано со спорными API/Kafka или E2E-классификациями.
1	Шаблон и обязательные атрибуты	5.0/10	Среднее по 24 ТК: структура есть, но часть экспортов не содержит прямых ссылок на атомарные требования, поэтому оценка ниже целевых 100%.
1	Предусловия и постусловия	8.0/10	Среднее по 24 ТК: предусловия в основном есть, но постусловия часто отсутствуют или не выделены отдельно.
1	Атомарность шагов	9.0/10	Среднее по 24 ТК: шаги в основном атомарны; отдельные снижения связаны со склейкой нескольких действий или проверок в одном шаге.
1	Ожидаемый результат	8.5/10	Среднее по 24 ТК: ожидаемые результаты заполнены, но часть результатов объединяет несколько проверок или требует уточнения.
1	Достоверность	7.6/10	Среднее по 24 ТК: диапазон оценок 4.0-10.0; снижение связано с неподтвержденными endpoint/status/role деталями и производными сценариями.

Раунд	Критерий	Score	Почему такая оценка
2	Корректность вида ТК	9.8/10	Среднее по 51 ТК: типы в основном совпадают с названиями/метками; снижение связано со спорными API/Кafka или E2E-классификациями.
2	Шаблон и обязательные атрибуты	7.5/10	Среднее по 51 ТК: структура есть, но часть экспортов не содержит прямых ссылок на атомарные требования, поэтому оценка ниже целевых 100%.
2	Предусловия и постусловия	8.2/10	Среднее по 51 ТК: предусловия в основном есть, но постусловия часто отсутствуют или не выделены отдельно.
2	Атомарность шагов	9.4/10	Среднее по 51 ТК: шаги в основном атомарны; отдельные снижения связаны со склейкой нескольких действий или проверок в одном шаге.
2	Ожидаемый результат	8.6/10	Среднее по 51 ТК: ожидаемые результаты заполнены, но часть результатов объединяет несколько проверок или требует уточнения.
2	Достоверность	8.6/10	Среднее по 51 ТК: диапазон оценок 0.0-10.0; снижение связано с неподтвержденными endpoint/status/role деталями и производными сценариями.
3	Корректность вида ТК	9.8/10	Среднее по 35 ТК: типы в основном совпадают с названиями/метками; снижение связано со спорными API/Кafka или E2E-классификациями.
3	Шаблон и обязательные атрибуты	7.9/10	Среднее по 35 ТК: структура есть, но часть экспортов не содержит прямых ссылок на атомарные требования, поэтому оценка ниже целевых 100%.
3	Предусловия и постусловия	8.2/10	Среднее по 35 ТК: предусловия в основном есть, но постусловия часто отсутствуют или не выделены отдельно.
3	Атомарность шагов	9.3/10	Среднее по 35 ТК: шаги в основном атомарны; отдельные снижения связаны со склейкой нескольких действий или проверок в одном шаге.
3	Ожидаемый результат	8.6/10	Среднее по 35 ТК: ожидаемые результаты заполнены, но часть результатов объединяет несколько проверок или требует уточнения.
3	Достоверность	9.8/10	Среднее по 35 ТК: диапазон оценок 4.0-10.0; снижение связано с неподтвержденными endpoint/status/role деталями и производными сценариями.

Вердикт

Механизм оценки работает на нескольких раундах: каждый прогон хранится отдельно, сгенерированные ТК связаны с требованиями, оценки сохранены по критериям и собираются в нарастающий отчет. Оценки являются демо-разметкой Codex и требуют ручного ревью перед управленческим решением.