

# Отчет по eval-прогонам

Методология оценок: [exports/pdf/methodology/scoring\\_methodology.pdf](#).

Формат отчета: цели берутся из БД, колонки раундов строятся нарастающим итогом по таблице **eval\_runs**.

Декомпозиция требований в импортированных Excel-раундах не передавалась, поэтому ее критерии пока не измерялись.

## Параметры прогонов

| Раунд | Run code | ТК | Что изменили                                                                                                                                                                           | Агент         | Модель | Temperature | Top P | Режим             |
|-------|----------|----|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------|--------|-------------|-------|-------------------|
| 1     | v0       | 24 | Тестовый демо-прогон v0: человекочитаемый экспорт ТК, без полных данных об агенте, промпте и декомпозиции.                                                                             | text_demo v0  | v0     | 0.0         | 1.0   | direct_extraction |
| 2     | v1       | 51 | Раунд v1: импорт из output_v1.xlsx, 51 сгенерированный ТК из папки prompts_v1.                                                                                                         | prompts_v1 v1 | v1     | 0.0         | 1.0   | direct_extraction |
| 3     | v2       | 35 | Раунд v2: импорт из output_v2.xlsx, набор сокращен и структурирован относительно v1.                                                                                                   | prompts_v2 v2 | v2     | 0.0         | 1.0   | direct_extraction |
| 4     | v3       | 43 | Раунд v3: импорт из txt-экспорта tc-export-326428, 43 сгенерированных ТК. Файл версии агента, промпты и декомпозиция требований не переданы; параметры агента заполнены заглушками v3. | v3            | v3     | 0.0         | 1.0   | direct_extraction |

| Раунд | Run code  | ТК | Что изменили                                                                                                                                                                                  | Агент | Модель | Temperature | Top P | Режим             |
|-------|-----------|----|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------|--------|-------------|-------|-------------------|
| 5     | <b>v4</b> | 48 | Раунд v4: импорт из txt-экспорта tc-export -c0ee93a8.txt, 48 сгенерированных ТК. Файл версии агента, промпты и декомпозиция требований не переданы; параметры агента заполнены заглушками v4. | v4    | v4     | 0.0         | 1.0   | direct_extraction |
| 6     | <b>v5</b> | 86 | Раунд v5: импорт из txt-экспорта tc-export -b5517cb2.txt, 86 сгенерированных ТК. Файл версии агента, промпты и декомпозиция требований не переданы; параметры агента заполнены заглушками v5. | v5    | v5     | 0.0         | 1.0   | direct_extraction |
| 7     | <b>v6</b> | 24 | Раунд v6: импорт из txt-экспорта tc-export -d7ec3594.txt, 24 сгенерированных ТК. Файл версии агента, промпты и декомпозиция требований не переданы; параметры агента заполнены заглушками v6. | v6    | v6     | 0.0         | 1.0   | direct_extraction |

## TOP benchmark

TOP benchmark - это лучшая предыдущая версия агента по текущей методике оценки. Она используется как точка сравнения, чтобы новый раунд оценивался не только относительно прошлого запуска, но и относительно лучшего результата, который уже был получен ранее.

| Поле            | Значение                     |
|-----------------|------------------------------|
| Режим сравнения | автоматический TOP benchmark |
| TOP benchmark   | <b>v3</b>                    |

| Поле          | Значение                                                                                 |
|---------------|------------------------------------------------------------------------------------------|
| Почему выбран | Общая полнота набора: 8.7/10; чистота набора: 6.6/10; достоверность отдельных ТК: 9.2/10 |

Текущий раунд **v6** сравнивается с **v3**, которая сейчас является TOP benchmark.

Начиная с третьего раунда benchmark выбирается среди всех предыдущих раундов: сначала по общей полноте набора, затем по чистоте набора, затем по достоверности отдельных ТК.

## 1. Декомпозиция требований

| Критерий                | Цель | Baseline | Раунд 1 | Раунд 2 | Раунд 3 | Раунд 4 | Раунд 5 | Раунд 6 | Раунд 7 |
|-------------------------|------|----------|---------|---------|---------|---------|---------|---------|---------|
| Полнота декомпозиции    | 100% | —        | —       | —       | —       | —       | —       | —       | —       |
| Границы требований      | 100% | —        | —       | —       | —       | —       | —       | —       | —       |
| Консолидация требований | 100% | —        | —       | —       | —       | —       | —       | —       | —       |

### Вывод по блоку декомпозиции

Для текущего раунда **v6** результат декомпозиции требований от агента не импортировался. На вход отчета передавались только сгенерированные тест-кейсы. Поэтому критерии **decomposition\_completeness**, **decomposition\_boundaries** и **requirement\_consolidation** пока не измерялись.

## 2. Набор ТК

| Критерий                       | Цель     | Baseline | Раунд 1 | Раунд 2 | Раунд 3 | Раунд 4 | Раунд 5 | Раунд 6 | Раунд 7 |
|--------------------------------|----------|----------|---------|---------|---------|---------|---------|---------|---------|
| Позитивное покрытие            | 100%     | —        | 7.0/10  | 9.3/10  | 8.2/10  | 8.9/10  | 7.9/10  | 8.2/10  | 8.6/10  |
| Негативное покрытие            | 100%     | —        | 6.0/10  | 10.0/10 | 9.0/10  | 9.0/10  | 4.0/10  | 3.0/10  | 5.0/10  |
| Чистота набора                 | 0 лишних | —        | 4.0/10  | 3.6/10  | 7.0/10  | 6.6/10  | 4.0/10  | 4.0/10  | 9.4/10  |
| Покрытие обязательных проверок | 100%     | —        | 6.5/10  | 10.0/10 | 9.6/10  | 10.0/10 | 8.6/10  | 8.6/10  | 9.6/10  |
| Общая полнота набора           | 100%     | —        | 6.0/10  | 7.5/10  | 8.5/10  | 8.7/10  | 6.4/10  | 6.2/10  | 8.4/10  |

### Вывод по блоку набора ТК

| Раунд | Критерий            | Score  | Почему такая оценка                                                            |
|-------|---------------------|--------|--------------------------------------------------------------------------------|
| 7     | Позитивное покрытие | 8.6/10 | Позитивные ТК покрывают 24 из 28 эталонных требований MVP.                     |
| 7     | Негативное покрытие | 5.0/10 | Негативные ТК покрывают 5 из 10 требований, где негативные проверки применимы. |

| Раунд | Критерий                       | Score  | Почему такая оценка                                                                    |
|-------|--------------------------------|--------|----------------------------------------------------------------------------------------|
| 7     | Чистота набора                 | 9.4/10 | В наборе 24 ТК; 1 ТК имеет заметный риск неподтвержденных деталей.                     |
| 7     | Покрытие обязательных проверок | 9.6/10 | Эвристическая трассировка нашла покрытие 27 из 28 обязательных требований.             |
| 7     | Общая полнота набора           | 8.4/10 | Итог учитывает позитивное/негативное покрытие, обязательные проверки и чистоту набора. |

### 3. Отдельные ТК

| Критерий                       | Цель           | Baseline | Раунд 1 | Раунд 2 | Раунд 3 | Раунд 4 | Раунд 5 | Раунд 6 | Раунд 7 |
|--------------------------------|----------------|----------|---------|---------|---------|---------|---------|---------|---------|
| Корректность вида ТК           | ≥0,9           | —        | 9.9/10  | 9.8/10  | 9.8/10  | 9.8/10  | 9.3/10  | 9.3/10  | 9.9/10  |
| Шаблон и обязательные атрибуты | 100%           | —        | 5.0/10  | 7.5/10  | 7.9/10  | 6.5/10  | 6.0/10  | 6.0/10  | 6.0/10  |
| Предусловия и постусловия      | ≥0,9           | —        | 8.0/10  | 8.2/10  | 8.2/10  | 8.2/10  | 8.0/10  | 8.0/10  | 8.1/10  |
| Атомарность шагов              | ≥0,9           | —        | 9.0/10  | 9.4/10  | 9.3/10  | 8.9/10  | 9.4/10  | 9.4/10  | 9.5/10  |
| Ожидаемый результат            | ≥0,9           | —        | 8.5/10  | 8.6/10  | 8.6/10  | 8.7/10  | 8.9/10  | 9.0/10  | 8.9/10  |
| Достоверность                  | галлюцинаций 0 | —        | 7.6/10  | 8.6/10  | 9.8/10  | 9.2/10  | 9.9/10  | 10.0/10 | 9.8/10  |

### Вывод по блоку отдельных ТК

| Раунд | Критерий                       | Score  | Почему такая оценка                                                                                                                       |
|-------|--------------------------------|--------|-------------------------------------------------------------------------------------------------------------------------------------------|
| 7     | Корректность вида ТК           | 9.9/10 | Среднее по 24 ТК: типы в основном совпадают с названиями/метками; снижение связано со спорными API/Kafka или E2E-классификациями.         |
| 7     | Шаблон и обязательные атрибуты | 6.0/10 | Среднее по 24 ТК: структура есть, но часть экспортов не содержит прямых ссылок на атомарные требования, поэтому оценка ниже целевых 100%. |
| 7     | Предусловия и постусловия      | 8.1/10 | Среднее по 24 ТК: предусловия в основном есть, но постусловия часто отсутствуют или не выделены отдельно.                                 |
| 7     | Атомарность шагов              | 9.5/10 | Среднее по 24 ТК: шаги в основном атомарны; отдельные снижения связаны со склейкой нескольких действий или проверок в одном шаге.         |
| 7     | Ожидаемый результат            | 8.9/10 | Среднее по 24 ТК: ожидаемые результаты заполнены, но часть результатов объединяет несколько проверок или требует уточнения.               |
| 7     | Достоверность                  | 9.8/10 | Среднее по 24 ТК: диапазон оценок 4.0-10.0; снижение связано с неподтвержденными endpoint/status/role деталями и производными сценариями. |

## Вердикт

Сравнение текущего раунда **v6** с TOP benchmark **v3**.

### Что улучшилось

- Чистота набора: 6.6 -> 9.4 (+2.8)
- Атомарность шагов: 8.9 -> 9.5 (+0.6)
- Ожидаемый результат: 8.7 -> 8.9 (+0.2)
- Достоверность: 9.2 -> 9.8 (+0.6)

### Что ухудшилось

- Позитивное покрытие: 8.9 -> 8.6 (-0.3)
- Негативное покрытие: 9.0 -> 5.0 (-4.0)
- Покрытие обязательных проверок: 10.0 -> 9.6 (-0.4)
- Общая полнота набора: 8.7 -> 8.4 (-0.3)
- Шаблон и обязательные атрибуты: 6.5 -> 6.0 (-0.5)

### Без существенных изменений

- Корректность вида ТК: 9.8 -> 9.9 (+0.1)
- Предусловия и постусловия: 8.2 -> 8.1 (-0.1)

### Общий вывод

Изменение агента в текущем раунде привело к следующему результату: общая полнота набора изменилась с 8.7 до 8.4; чистота набора изменилась с 6.6 до 9.4; позитивное покрытие изменилось с 8.9 до 8.6; покрытие обязательных проверок изменилось с 10.0 до 9.6.

В целом текущая версия выглядит хуже benchmark **v3**: снижение общей полноты требует анализа причин.