

Отчет по eval-прогонам

Методология оценок: [exports/pdf/methodology/scoring_methodology.pdf](#).

Формат отчета: цели берутся из БД, колонки раундов строятся нарастающим итогом по таблице **eval_runs**.

Декомпозиция требований в импортированных Excel-раундах не передавалась, поэтому ее критерии пока не измерялись.

Параметры прогонов

Раунд	Run code	ТК	Что изменили	Агент	Модель	Temperature	Top P	Режим
1	v0	24	Тестовый демо-прогон v0: человекочитаемый экспорт ТК, без полных данных об агенте, промпте и декомпозиции.	text_demo v0	v0	0.0	1.0	direct_extraction

1. Декомпозиция требований

Критерий	Цель	Baseline	Раунд 1
Полнота декомпозиции	100%	—	—
Границы требований	100%	—	—
Консолидация требований	100%	—	—

Вывод по блоку декомпозиции

В текущих раундах на вход отчета передавались только сгенерированные тест-кейсы. Результат декомпозиции требований от агента не импортировался, поэтому критерии **decomposition_completeness**, **decomposition_boundaries** и **requirement_consolidation** пока не измерялись.

2. Набор ТК

Критерий	Цель	Baseline	Раунд 1
Позитивное покрытие	100%	—	7.0/10
Негативное покрытие	100%	—	6.0/10
Чистота набора	0 лишних	—	4.0/10

Критерий	Цель	Baseline	Раунд 1
Покрытие обязательных проверок	100%	—	6.5/10
Общая полнота набора	100%	—	6.0/10

Вывод по блоку набора ТК

Раунд	Критерий	Score	Почему такая оценка
1	Позитивное покрытие	7.0/10	Позитивные сценарии покрывают значимую часть эталона, но нет явного покрытия size/page, одного контура и полноценного E2E-сценария.
1	Негативное покрытие	6.0/10	Есть негативные UI/API проверки, но часть негативов производная или не подтверждена ТЗ.
1	Чистота набора	4.0/10	Набор раздроблен на 24 одношаговых ТК, есть дубли UI/API и проверки вне явно заданных endpoint в ТЗ.
1	Покрытие обязательных проверок	6.5/10	Часть обязательных проверок покрыта, но отсутствуют или слабо покрыты size/page, контурность, полноценная трассировка и часть эталонных комплексных сценариев.
1	Общая полнота набора	6.0/10	Набор демонстрирует основную возможность генерации ТК, но требует ручной чистки, объединения дублей и проверки трассировки.

3. Отдельные ТК

Критерий	Цель	Baseline	Раунд 1
Корректность вида ТК	≥0,9	—	9.9/10
Шаблон и обязательные атрибуты	100%	—	5.0/10
Предусловия и постусловия	≥0,9	—	8.0/10
Атомарность шагов	≥0,9	—	9.0/10
Ожидаемый результат	≥0,9	—	8.5/10
Достоверность	галлюцинаций 0	—	7.6/10

Вывод по блоку отдельных ТК

Раунд	Критерий	Score	Почему такая оценка
1	Корректность вида ТК	9.9/10	Среднее по 24 ТК: типы в основном совпадают с названиями/метками; снижение связано со спорными API/Кafka или E2E-классификациями.

Раунд	Критерий	Score	Почему такая оценка
1	Шаблон и обязательные атрибуты	5.0/10	Среднее по 24 ТК: структура есть, но часть экспортов не содержит прямых ссылок на атомарные требования, поэтому оценка ниже целевых 100%.
1	Предусловия и постусловия	8.0/10	Среднее по 24 ТК: предусловия в основном есть, но постусловия часто отсутствуют или не выделены отдельно.
1	Атомарность шагов	9.0/10	Среднее по 24 ТК: шаги в основном атомарны; отдельные снижения связаны со склейкой нескольких действий или проверок в одном шаге.
1	Ожидаемый результат	8.5/10	Среднее по 24 ТК: ожидаемые результаты заполнены, но часть результатов объединяет несколько проверок или требует уточнения.
1	Достоверность	7.6/10	Среднее по 24 ТК: диапазон оценок 4.0-10.0; снижение связано с неподтвержденными endpoint/status/role деталями и производными сценариями.

Вердикт

Механизм оценки работает на нескольких раундах: каждый прогон хранится отдельно, сгенерированные ТК связаны с требованиями, оценки сохранены по критериям и собираются в нарастающий отчет. Оценки являются демо-разметкой Codex и требуют ручного ревью перед управленческим решением.