

Отчет по eval-прогонам

Методология оценок: [exports/pdf/methodology/scoring_methodology.pdf](#).

Формат отчета: цели берутся из БД, колонки раундов строятся нарастающим итогом по таблице **eval_runs**.

Декомпозиция требований в импортированных Excel-раундах не передавалась, поэтому ее критерии пока не измерялись.

Параметры прогонов

Раунд	Run code	ТК	Что изменили	Агент	Модель	Temperature	Top P	Режим
1	v0	24	Тестовый демо-прогон v0: человекочитаемый экспорт ТК, без полных данных об агенте, промпте и декомпозиции.	text_demo v0	v0	0.0	1.0	direct_extraction
2	v1	51	Раунд v1: импорт из output_v1.xlsx, 51 сгенерированный ТК из папки prompts_v1.	prompts_v1 v1	v1	0.0	1.0	direct_extraction

1. Декомпозиция требований

Критерий	Цель	Baseline	Раунд 1	Раунд 2
Полнота декомпозиции	100%	—	—	—
Границы требований	100%	—	—	—
Консолидация требований	100%	—	—	—

Вывод по блоку декомпозиции

Для текущего раунда **v1** результат декомпозиции требований от агента не импортировался. На вход отчета передавались только сгенерированные тест-кейсы. Поэтому критерии **decomposition_completeness**, **decomposition_boundaries** и **requirement_consolidation** пока не измерялись.

2. Набор ТК

Критерий	Цель	Baseline	Раунд 1	Раунд 2
Позитивное покрытие	100%	—	7.0/10	9.3/10

Критерий	Цель	Baseline	Раунд 1	Раунд 2
Негативное покрытие	100%	—	6.0/10	10.0/10
Чистота набора	0 лишних	—	4.0/10	3.6/10
Покрытие обязательных проверок	100%	—	6.5/10	10.0/10
Общая полнота набора	100%	—	6.0/10	7.5/10

Вывод по блоку набора ТК

Раунд	Критерий	Score	Почему такая оценка
2	Позитивное покрытие	9.3/10	Позитивные ТК покрывают 26 из 28 эталонных требований MVP.
2	Негативное покрытие	10.0/10	Негативные ТК покрывают 10 из 10 требований, где негативные проверки применимы.
2	Чистота набора	3.6/10	В наборе 51 ТК; 14 ТК имеют заметный риск неподтвержденных деталей.
2	Покрытие обязательных проверок	10.0/10	Эвристическая трассировка нашла покрытие 28 из 28 обязательных требований.
2	Общая полнота набора	7.5/10	Итог учитывает позитивное/негативное покрытие, обязательные проверки и чистоту набора.

3. Отдельные ТК

Критерий	Цель	Baseline	Раунд 1	Раунд 2
Корректность вида ТК	≥0,9	—	9.9/10	9.8/10
Шаблон и обязательные атрибуты	100%	—	5.0/10	7.5/10
Предусловия и постусловия	≥0,9	—	8.0/10	8.2/10
Атомарность шагов	≥0,9	—	9.0/10	9.4/10
Ожидаемый результат	≥0,9	—	8.5/10	8.6/10
Достоверность	галлюцинаций 0	—	7.6/10	8.6/10

Вывод по блоку отдельных ТК

Раунд	Критерий	Score	Почему такая оценка
2	Корректность вида ТК	9.8/10	Среднее по 51 ТК: типы в основном совпадают с названиями/метками; снижение связано со спорными API/Kafka или E2E-классификациями.

Раунд	Критерий	Score	Почему такая оценка
2	Шаблон и обязательные атрибуты	7.5/10	Среднее по 51 ТК: структура есть, но часть экспортов не содержит прямых ссылок на атомарные требования, поэтому оценка ниже целевых 100%.
2	Предусловия и постусловия	8.2/10	Среднее по 51 ТК: предусловия в основном есть, но постусловия часто отсутствуют или не выделены отдельно.
2	Атомарность шагов	9.4/10	Среднее по 51 ТК: шаги в основном атомарны; отдельные снижения связаны со склейкой нескольких действий или проверок в одном шаге.
2	Ожидаемый результат	8.6/10	Среднее по 51 ТК: ожидаемые результаты заполнены, но часть результатов объединяет несколько проверок или требует уточнения.
2	Достоверность	8.6/10	Среднее по 51 ТК: диапазон оценок 0.0-10.0; снижение связано с неподтвержденными endpoint/status/role деталями и производными сценариями.

Вердикт

Механизм оценки работает на нескольких раундах: каждый прогон хранится отдельно, сгенерированные ТК связаны с требованиями, оценки сохранены по критериям и собираются в нарастающий отчет. Оценки являются демо-разметкой Codex и требуют ручного ревью перед управленческим решением.