

Отчет по eval-прогонам

Методология оценок: [exports/pdf/methodology/scoring_methodology.pdf](#).

Формат отчета: цели берутся из БД, колонки раундов строятся нарастающим итогом по таблице **eval_runs**.

Декомпозиция требований в импортированных Excel-раундах не передавалась, поэтому ее критерии пока не измерялись.

Параметры прогонов

Раунд	Run code	ТК	Что изменили	Агент	Модель	Temperature	Top P	Режим
1	v0	24	Тестовый демо-прогон v0: человекочитаемый экспорт ТК, без полных данных об агенте, промпте и декомпозиции.	text_demo v0	v0	0.0	1.0	direct_extraction
2	v1	51	Раунд v1: импорт из output_v1.xlsx, 51 сгенерированный ТК из папки prompts_v1.	prompts_v1 v1	v1	0.0	1.0	direct_extraction

TOP benchmark

TOP benchmark - это лучшая предыдущая версия агента по текущей методике оценки. Она используется как точка сравнения, чтобы новый раунд оценивался не только относительно прошлого запуска, но и относительно лучшего результата, который уже был получен ранее.

Поле	Значение
Режим сравнения	последовательное сравнение с предыдущим раундом
TOP benchmark	v0
Почему выбран	Общая полнота набора: 6.0/10; чистота набора: 4.0/10; достоверность отдельных ТК: 7.6/10

Текущий раунд **v1** сравнивается с **v0**, которая сейчас является TOP benchmark.

Начиная с третьего раунда benchmark выбирается среди всех предыдущих раундов: сначала по общей полноте набора, затем по чистоте набора, затем по достоверности отдельных ТК.

1. Декомпозиция требований

Критерий	Цель	Baseline	Раунд 1	Раунд 2
Полнота декомпозиции	100%	—	—	—
Границы требований	100%	—	—	—
Консолидация требований	100%	—	—	—

Вывод по блоку декомпозиции

Для текущего раунда **v1** результат декомпозиции требований от агента не импортировался. На вход отчета передавались только сгенерированные тест-кейсы. Поэтому критерии **decomposition_completeness**, **decomposition_boundaries** и **requirement_consolidation** пока не измерялись.

2. Набор ТК

Критерий	Цель	Baseline	Раунд 1	Раунд 2
Позитивное покрытие	100%	—	7.0/10	9.3/10
Негативное покрытие	100%	—	6.0/10	10.0/10
Чистота набора	0 лишних	—	4.0/10	3.6/10
Покрытие обязательных проверок	100%	—	6.5/10	10.0/10
Общая полнота набора	100%	—	6.0/10	7.5/10

Вывод по блоку набора ТК

Раунд	Критерий	Score	Почему такая оценка
2	Позитивное покрытие	9.3/10	Позитивные ТК покрывают 26 из 28 эталонных требований MVP.
2	Негативное покрытие	10.0/10	Негативные ТК покрывают 10 из 10 требований, где негативные проверки применимы.
2	Чистота набора	3.6/10	В наборе 51 ТК; 14 ТК имеют заметный риск неподтвержденных деталей.
2	Покрытие обязательных проверок	10.0/10	Эвристическая трассировка нашла покрытие 28 из 28 обязательных требований.
2	Общая полнота набора	7.5/10	Итог учитывает позитивное/негативное покрытие, обязательные проверки и чистоту набора.

3. Отдельные ТК

Критерий	Цель	Baseline	Раунд 1	Раунд 2
Корректность вида ТК	≥0,9	—	9.9/10	9.8/10
Шаблон и обязательные атрибуты	100%	—	5.0/10	7.5/10
Предусловия и постусловия	≥0,9	—	8.0/10	8.2/10
Атомарность шагов	≥0,9	—	9.0/10	9.4/10
Ожидаемый результат	≥0,9	—	8.5/10	8.6/10
Достоверность	галлюцинаций 0	—	7.6/10	8.6/10

Вывод по блоку отдельных ТК

Раунд	Критерий	Score	Почему такая оценка
2	Корректность вида ТК	9.8/10	Среднее по 51 ТК: типы в основном совпадают с названиями/метками; снижение связано со спорными API/Kafka или E2E-классификациями.
2	Шаблон и обязательные атрибуты	7.5/10	Среднее по 51 ТК: структура есть, но часть экспортов не содержит прямых ссылок на атомарные требования, поэтому оценка ниже целевых 100%.
2	Предусловия и постусловия	8.2/10	Среднее по 51 ТК: предусловия в основном есть, но постусловия часто отсутствуют или не выделены отдельно.
2	Атомарность шагов	9.4/10	Среднее по 51 ТК: шаги в основном атомарны; отдельные снижения связаны со склейкой нескольких действий или проверок в одном шаге.
2	Ожидаемый результат	8.6/10	Среднее по 51 ТК: ожидаемые результаты заполнены, но часть результатов объединяет несколько проверок или требует уточнения.
2	Достоверность	8.6/10	Среднее по 51 ТК: диапазон оценок 0.0-10.0; снижение связано с неподтвержденными endpoint/status/role деталями и производными сценариями.

Вердикт

Сравнение текущего раунда **v1** с предыдущим раундом **v0**.

Что улучшилось

- Позитивное покрытие: 7.0 -> 9.3 (+2.3)
- Негативное покрытие: 6.0 -> 10.0 (+4.0)

- Покрытие обязательных проверок: 6.5 -> 10.0 (+3.5)
- Общая полнота набора: 6.0 -> 7.5 (+1.5)
- Шаблон и обязательные атрибуты: 5.0 -> 7.5 (+2.5)
- Предусловия и постусловия: 8.0 -> 8.2 (+0.2)
- Атомарность шагов: 9.0 -> 9.4 (+0.4)
- Достоверность: 7.6 -> 8.6 (+1.0)

Что ухудшилось

- Чистота набора: 4.0 -> 3.6 (-0.4)

Без существенных изменений

- Корректность вида ТК: 9.9 -> 9.8 (-0.1)
- Ожидаемый результат: 8.5 -> 8.6 (+0.1)

Общий вывод

Изменение агента в текущем раунде привело к следующему результату: общая полнота набора изменилась с 6.0 до 7.5; чистота набора изменилась с 4.0 до 3.6; позитивное покрытие изменилось с 7.0 до 9.3; покрытие обязательных проверок изменилось с 6.5 до 10.0.

В целом текущая версия выглядит лучше benchmark **v0**, потому что ключевой показатель выбора TOP benchmark — общая полнота набора — вырос с 6.0 до 7.5. Рост обеспечен улучшением критериев: позитивное покрытие, негативное покрытие, покрытие обязательных проверок, шаблон и обязательные атрибуты, предусловия и постусловия, атомарность шагов, достоверность. При этом есть ограничения: просели критерии чистота набора.