

Отчет по eval-прогонам

Методология оценок: [exports/pdf/methodology/scoring_methodology.pdf](#).

Формат отчета: цели берутся из БД, колонки раундов строятся нарастающим итогом по таблице **eval_runs**.

Декомпозиция требований в импортированных Excel-раундах не передавалась, поэтому ее критерии пока не измерялись.

Параметры прогонов

Раунд	Run code	ТК	Что изменили	Агент	Модель	Temperature	Top P	Режим
1	v0	24	Тестовый демо-прогон v0: человекочитаемый экспорт ТК, без полных данных об агенте, промпте и декомпозиции.	text_demo v0	v0	0.0	1.0	direct_extraction
2	v1	51	Раунд v1: импорт из output_v1.xlsx, 51 сгенерированный ТК из папки prompts_v1.	prompts_v1 v1	v1	0.0	1.0	direct_extraction
3	v2	35	Раунд v2: импорт из output_v2.xlsx, набор сокращен и структурирован относительно v1.	prompts_v2 v2	v2	0.0	1.0	direct_extraction

TOP benchmark

TOP benchmark - это лучшая предыдущая версия агента по текущей методике оценки. Она используется как точка сравнения, чтобы новый раунд оценивался не только относительно прошлого запуска, но и относительно лучшего результата, который уже был получен ранее.

Поле	Значение
Режим сравнения	автоматический TOP benchmark
TOP benchmark	v1
Почему выбран	Общая полнота набора: 7.5/10; чистота набора: 3.6/10; достоверность отдельных ТК: 8.6/10

Текущий раунд **v2** сравнивается с **v1**, которая сейчас является TOP benchmark.

Начиная с третьего раунда benchmark выбирается среди всех предыдущих раундов: сначала по общей полноте набора, затем по чистоте набора, затем по достоверности отдельных ТК.

1. Декомпозиция требований

Критерий	Цель	Baseline	Раунд 1	Раунд 2	Раунд 3
Полнота декомпозиции	100%	—	—	—	—
Границы требований	100%	—	—	—	—
Консолидация требований	100%	—	—	—	—

Вывод по блоку декомпозиции

Для текущего раунда **v2** результат декомпозиции требований от агента не импортировался. На вход отчета передавались только сгенерированные тест-кейсы. Поэтому критерии **decomposition_completeness**, **decomposition_boundaries** и **requirement_consolidation** пока не измерялись.

2. Набор ТК

Критерий	Цель	Baseline	Раунд 1	Раунд 2	Раунд 3
Позитивное покрытие	100%	—	7.0/10	9.3/10	8.2/10
Негативное покрытие	100%	—	6.0/10	10.0/10	9.0/10
Чистота набора	0 лишних	—	4.0/10	3.6/10	7.0/10
Покрытие обязательных проверок	100%	—	6.5/10	10.0/10	9.6/10
Общая полнота набора	100%	—	6.0/10	7.5/10	8.5/10

Вывод по блоку набора ТК

Раунд	Критерий	Score	Почему такая оценка
3	Позитивное покрытие	8.2/10	Позитивные ТК покрывают 23 из 28 эталонных требований MVP.
3	Негативное покрытие	9.0/10	Негативные ТК покрывают 9 из 10 требований, где негативные проверки применимы.
3	Чистота набора	7.0/10	В наборе 35 ТК; 2 ТК имеют заметный риск неподтвержденных деталей.
3	Покрытие обязательных проверок	9.6/10	Эвристическая трассировка нашла покрытие 27 из 28 обязательных требований.
3	Общая полнота набора	8.5/10	Итог учитывает позитивное/негативное покрытие, обязательные проверки и чистоту набора.

3. Отдельные ТК

Критерий	Цель	Baseline	Раунд 1	Раунд 2	Раунд 3
Корректность вида ТК	≥0,9	—	9.9/10	9.8/10	9.8/10
Шаблон и обязательные атрибуты	100%	—	5.0/10	7.5/10	7.9/10
Предусловия и постусловия	≥0,9	—	8.0/10	8.2/10	8.2/10
Атомарность шагов	≥0,9	—	9.0/10	9.4/10	9.3/10
Ожидаемый результат	≥0,9	—	8.5/10	8.6/10	8.6/10
Достоверность	галлюцинаций 0	—	7.6/10	8.6/10	9.8/10

Вывод по блоку отдельных ТК

Раунд	Критерий	Score	Почему такая оценка
3	Корректность вида ТК	9.8/10	Среднее по 35 ТК: типы в основном совпадают с названиями/метками; снижение связано со спорными API/Kafka или E2E-классификациями.
3	Шаблон и обязательные атрибуты	7.9/10	Среднее по 35 ТК: структура есть, но часть экспортов не содержит прямых ссылок на атомарные требования, поэтому оценка ниже целевых 100%.
3	Предусловия и постусловия	8.2/10	Среднее по 35 ТК: предусловия в основном есть, но постусловия часто отсутствуют или не выделены отдельно.
3	Атомарность шагов	9.3/10	Среднее по 35 ТК: шаги в основном атомарны; отдельные снижения связаны со склейкой нескольких действий или проверок в одном шаге.
3	Ожидаемый результат	8.6/10	Среднее по 35 ТК: ожидаемые результаты заполнены, но часть результатов объединяет несколько проверок или требует уточнения.
3	Достоверность	9.8/10	Среднее по 35 ТК: диапазон оценок 4.0-10.0; снижение связано с неподтвержденными endpoint/status/role деталями и производными сценариями.

Вердикт

Сравнение текущего раунда **v2** с TOP benchmark **v1**.

Что улучшилось

- Чистота набора: 3.6 -> 7.0 (+3.4)
- Общая полнота набора: 7.5 -> 8.5 (+1.0)
- Шаблон и обязательные атрибуты: 7.5 -> 7.9 (+0.4)
- Достоверность: 8.6 -> 9.8 (+1.2)

Что ухудшилось

- Позитивное покрытие: 9.3 -> 8.2 (-1.1)
- Негативное покрытие: 10.0 -> 9.0 (-1.0)
- Покрытие обязательных проверок: 10.0 -> 9.6 (-0.4)

Без существенных изменений

- Корректность вида ТК: 9.8 -> 9.8 (+0.0)
- Предусловия и постусловия: 8.2 -> 8.2 (+0.0)
- Атомарность шагов: 9.4 -> 9.3 (-0.1)
- Ожидаемый результат: 8.6 -> 8.6 (+0.0)

Общий вывод

Изменение агента в текущем раунде привело к следующему результату: общая полнота набора изменилась с 7.5 до 8.5; чистота набора изменилась с 3.6 до 7.0; позитивное покрытие изменилось с 9.3 до 8.2; покрытие обязательных проверок изменилось с 10.0 до 9.6.

В целом текущая версия выглядит лучше benchmark **v1**: набор стал более пригодным для использования, при отдельных просадках по критериям: позитивное покрытие, негативное покрытие, покрытие обязательных проверок.