

Отчет по eval-прогонам

Методология оценок: [exports/pdf/methodology/scoring_methodology.pdf](#).

Формат отчета: цели берутся из БД, колонки раундов строятся нарастающим итогом по таблице **eval_runs**.

Декомпозиция требований в импортированных Excel-раундах не передавалась, поэтому ее критерии пока не измерялись.

Параметры прогонов

Раунд	Run code	ТК	Что изменили	Агент	Модель	Temperature	Top P	Режим
1	v0	24	Тестовый демо-прогон v0: человекочитаемый экспорт ТК, без полных данных об агенте, промпте и декомпозиции.	text_demo v0	v0	0.0	1.0	direct_extraction
2	v1	51	Раунд v1: импорт из output_v1.xlsx, 51 сгенерированный ТК из папки prompts_v1.	prompts_v1 v1	v1	0.0	1.0	direct_extraction
3	v2	35	Раунд v2: импорт из output_v2.xlsx, набор сокращен и структурирован относительно v1.	prompts_v2 v2	v2	0.0	1.0	direct_extraction
4	v3	43	Раунд v3: импорт из txt-экспорта tc-export-326428, 43 сгенерированных ТК. Файл версии агента, промпты и декомпозиция требований не переданы; параметры агента заполнены заглушками v3.	v3	v3	0.0	1.0	direct_extraction

Раунд	Run code	ТК	Что изменили	Агент	Модель	Temperature	Top P	Режим
5	v4	48	Раунд v4: импорт из txt-экспорта tc-export -c0ee93a8.txt, 48 сгенерированных ТК. Файл версии агента, промпты и декомпозиция требований не переданы; параметры агента заполнены заглушками v4.	v4	v4	0.0	1.0	direct_extraction
6	v5	86	Раунд v5: импорт из txt-экспорта tc-export -b5517cb2.txt, 86 сгенерированных ТК. Файл версии агента, промпты и декомпозиция требований не переданы; параметры агента заполнены заглушками v5.	v5	v5	0.0	1.0	direct_extraction

TOP benchmark

TOP benchmark - это лучшая предыдущая версия агента по текущей методике оценки. Она используется как точка сравнения, чтобы новый раунд оценивался не только относительно прошлого запуска, но и относительно лучшего результата, который уже был получен ранее.

Поле	Значение
Режим сравнения	автоматический TOP benchmark
TOP benchmark	v3
Почему выбран	Общая полнота набора: 8.7/10; чистота набора: 6.6/10; достоверность отдельных ТК: 9.2/10

Текущий раунд **v5** сравнивается с **v3**, которая сейчас является TOP benchmark.

Начиная с третьего раунда benchmark выбирается среди всех предыдущих раундов: сначала по общей полноте набора, затем по чистоте набора, затем по достоверности отдельных ТК.

1. Декомпозиция требований

Критерий	Цель	Baseline	Раунд 1	Раунд 2	Раунд 3	Раунд 4	Раунд 5	Раунд 6
Полнота декомпозиции	100%	—	—	—	—	—	—	—
Границы требований	100%	—	—	—	—	—	—	—
Консолидация требований	100%	—	—	—	—	—	—	—

Вывод по блоку декомпозиции

Для текущего раунда **v5** результат декомпозиции требований от агента не импортировался. На вход отчета передавались только сгенерированные тест-кейсы. Поэтому критерии **decomposition_completeness**, **decomposition_boundaries** и **requirement_consolidation** пока не измерялись.

2. Набор ТК

Критерий	Цель	Baseline	Раунд 1	Раунд 2	Раунд 3	Раунд 4	Раунд 5	Раунд 6
Позитивное покрытие	100%	—	7.0/10	9.3/10	8.2/10	8.9/10	7.9/10	8.2/10
Негативное покрытие	100%	—	6.0/10	10.0/10	9.0/10	9.0/10	4.0/10	3.0/10
Чистота набора	0 лишних	—	4.0/10	3.6/10	7.0/10	6.6/10	4.0/10	4.0/10
Покрывтие обязательных проверок	100%	—	6.5/10	10.0/10	9.6/10	10.0/10	8.6/10	8.6/10
Общая полнота набора	100%	—	6.0/10	7.5/10	8.5/10	8.7/10	6.4/10	6.2/10

Вывод по блоку набора ТК

Раунд	Критерий	Score	Почему такая оценка
6	Позитивное покрытие	8.2/10	Позитивные ТК покрывают 23 из 28 эталонных требований MVP.
6	Негативное покрытие	3.0/10	Негативные ТК покрывают 3 из 10 требований, где негативные проверки применимы.
6	Чистота набора	4.0/10	В наборе 86 ТК; 1 ТК имеет заметный риск неподтвержденных деталей; размер набора выше 45 ТК создает высокий риск дублей и лишних проверок.
6	Покрывтие обязательных проверок	8.6/10	Эвристическая трассировка нашла покрытие 24 из 28 обязательных требований.
6	Общая полнота набора	6.2/10	Итог учитывает позитивное/негативное покрытие, обязательные проверки и чистоту набора.

3. Отдельные ТК

Критерий	Цель	Baseline	Раунд 1	Раунд 2	Раунд 3	Раунд 4	Раунд 5	Раунд 6
Корректность вида ТК	≥0,9	—	9.9/10	9.8/10	9.8/10	9.8/10	9.3/10	9.3/10
Шаблон и обязательные атрибуты	100%	—	5.0/10	7.5/10	7.9/10	6.5/10	6.0/10	6.0/10
Предусловия и постусловия	≥0,9	—	8.0/10	8.2/10	8.2/10	8.2/10	8.0/10	8.0/10
Атомарность шагов	≥0,9	—	9.0/10	9.4/10	9.3/10	8.9/10	9.4/10	9.4/10
Ожидаемый результат	≥0,9	—	8.5/10	8.6/10	8.6/10	8.7/10	8.9/10	9.0/10
Достоверность	галлюцинаций 0	—	7.6/10	8.6/10	9.8/10	9.2/10	9.9/10	10.0/10

Вывод по блоку отдельных ТК

Раунд	Критерий	Score	Почему такая оценка
6	Корректность вида ТК	9.3/10	Среднее по 86 ТК: типы в основном совпадают с названиями/метками; снижение связано со спорными API/Kafka или E2E-классификациями.
6	Шаблон и обязательные атрибуты	6.0/10	Среднее по 86 ТК: структура есть, но часть экспортов не содержит прямых ссылок на атомарные требования, поэтому оценка ниже целевых 100%.
6	Предусловия и постусловия	8.0/10	Среднее по 86 ТК: предусловия в основном есть, но постусловия часто отсутствуют или не выделены отдельно.
6	Атомарность шагов	9.4/10	Среднее по 86 ТК: шаги в основном атомарны; отдельные снижения связаны со склейкой нескольких действий или проверок в одном шаге.
6	Ожидаемый результат	9.0/10	Среднее по 86 ТК: ожидаемые результаты заполнены, но часть результатов объединяет несколько проверок или требует уточнения.
6	Достоверность	10.0/10	Среднее по 86 ТК: диапазон оценок 7.5-10.0; снижение связано с неподтвержденными endpoint/status/role деталями и производными сценариями.

Вердикт

Сравнение текущего раунда **v5** с TOP benchmark **v3**.

Что улучшилось

- Атомарность шагов: 8.9 -> 9.4 (+0.5)
- Ожидаемый результат: 8.7 -> 9.0 (+0.3)

- Достоверность: 9.2 -> 10.0 (+0.8)

Что ухудшилось

- Позитивное покрытие: 8.9 -> 8.2 (-0.7)
- Негативное покрытие: 9.0 -> 3.0 (-6.0)
- Чистота набора: 6.6 -> 4.0 (-2.6)
- Покрытие обязательных проверок: 10.0 -> 8.6 (-1.4)
- Общая полнота набора: 8.7 -> 6.2 (-2.5)
- Корректность вида ТК: 9.8 -> 9.3 (-0.5)
- Шаблон и обязательные атрибуты: 6.5 -> 6.0 (-0.5)
- Предусловия и постусловия: 8.2 -> 8.0 (-0.2)

Без существенных изменений

- Критериев без существенной динамики нет.

Общий вывод

Изменение агента в текущем раунде привело к следующему результату: общая полнота набора изменилась с 8.7 до 6.2; чистота набора изменилась с 6.6 до 4.0; позитивное покрытие изменилось с 8.9 до 8.2; покрытие обязательных проверок изменилось с 10.0 до 8.6.

В целом текущая версия выглядит хуже benchmark **v3**: снижение общей полноты требует анализа причин.