

# Методика выставления оценок

Документ описывает, как выставлять оценки по шкале **0..10** в MVP eval-процесса.

Оценка хранится как **REAL**, поэтому допустимы целые и дробные значения.

## Общая шкала

| Оценка | Общая интерпретация                                                                 |
|--------|-------------------------------------------------------------------------------------|
| 10     | Эталон: критерий выполнен полностью, замечаний нет.                                 |
| 9      | Почти эталон: есть единичные minor-замечания без влияния на итог.                   |
| 8      | Хорошо: результат пригоден, но есть несколько небольших замечаний.                  |
| 7      | Приемлемо: основная польза есть, но есть заметные пропуски.                         |
| 6      | Нижняя граница приемлемого: результат можно использовать только после доработки.    |
| 5      | Слабо: критерий выполнен примерно наполовину или сильно нестабилен.                 |
| 4      | Плохо: есть отдельные полезные элементы, но качество мешает использовать результат. |
| 3      | Очень плохо: выполнены только единичные элементы критерия.                          |
| 2      | Почти отсутствует: есть следы выполнения, но практической пользы почти нет.         |
| 1      | Минимальное соответствие: найден один слабый признак выполнения критерия.           |
| 0      | Критерий не выполнен или сущность отсутствует.                                      |

## 1. Сгенерированные требования / декомпозиция

Эти критерии применяются к требованиям, которые агент получил после декомпозиции исходного материала.

Сравнение идет с эталонными атомарными требованиями.

### decomposition\_completeness - Полнота декомпозиции

Проверяет, все ли значимые атомарные требования из эталона были выделены агентом.

Основной расчет:

$$\text{score} = \text{найденные значимые атомарные требования} / \text{эталонные атомарные требования} * 10$$

Оценка снижается, если требование формально найдено, но искажено по смыслу.

| Оценка | Когда ставим                                                                             |
|--------|------------------------------------------------------------------------------------------|
| 10     | Все значимые атомарные требования выделены, потерь и смысловых искажений нет.            |
| 9      | Пропущена только незначительная деталь, на генерацию ТК почти не влияет.                 |
| 8      | Есть 1-2 minor-пропуска, основные требования сохранены.                                  |
| 7      | Выделена основная часть требований, но есть заметные пропуски.                           |
| 6      | Основа сохранена, но пропущено несколько важных ограничений или условий.                 |
| 5      | Выделено около половины полезного содержания.                                            |
| 4      | Потеряна существенная часть требований, результат требует почти полной ручной доработки. |
| 3      | Найдены только отдельные требования, большая часть смысла потеряна.                      |
| 2      | Есть единичные фрагменты требований без полноценной декомпозиции.                        |
| 1      | Есть один слабый признак исходного требования, но результат почти непригоден.            |
| 0      | Декомпозиция отсутствует или не отражает входное требование.                             |

### decomposition\_boundaries - Границы требований

Проверяет, корректно ли агент нарезал требования: не склеил независимые требования и не раздробил одно требование на бессмысленные части.

При наличии точной разметки:

score = требования с корректными границами / проверенные требования \* 10

Если точной разметки нет, используется экспертная оценка.

| Оценка | Когда ставим                                                                       |
|--------|------------------------------------------------------------------------------------|
| 10     | Все требования выделены самостоятельными проверяемыми единицами.                   |
| 9      | Есть единичное спорное разделение или объединение без влияния на проверяемость.    |
| 8      | Есть несколько minor-спорных границ, но структура в целом корректна.               |
| 7      | Большая часть границ корректна, но есть заметные склейки или лишнее дробление.     |
| 6      | Границы частично корректны, но часть требований неудобна для генерации ТК.         |
| 5      | Примерно половина требований нарезана спорно.                                      |
| 4      | Границы часто нарушены: независимые требования склеены или атомарность потеряна.   |
| 3      | Большая часть результата состоит из некорректных или несамостоятельных фрагментов. |
| 2      | Есть отдельные попытки нарезки, но они почти не помогают проверке.                 |
| 1      | Границы почти не определены, есть только случайные фрагменты.                      |
| 0      | Границы не определены или декомпозиция непригодна.                                 |

## requirement\_consolidation - Консолидация требований

Проверяет, корректно ли агент объединяет одинаковую или связанную информацию из разных источников: без дублей, противоречий и потери смысла.

При наличии точной разметки:

score = корректно объединенные связи / связи, которые нужно было объединить \* 10

| Оценка | Когда ставим                                                                           |
|--------|----------------------------------------------------------------------------------------|
| 10     | Связанная информация объединена корректно, дублей и противоречий нет.                  |
| 9      | Есть единичный minor-дубль или minor-потеря контекста.                                 |
| 8      | Консолидация в целом корректна, но есть несколько небольших дублей.                    |
| 7      | Большая часть связанной информации объединена, но часть требует ревью.                 |
| 6      | Есть полезная консолидация, но заметны дубли или потеря связей.                        |
| 5      | Консолидация выполнена примерно наполовину.                                            |
| 4      | Есть заметные дубли, несогласованные формулировки или потеря связей между источниками. |
| 3      | Агент почти не консолидирует связанные требования и плодит дубли.                      |
| 2      | Есть единичная попытка объединения, но она почти не помогает.                          |
| 1      | Консолидация случайная и практически непригодная.                                      |
| 0      | Консолидация отсутствует или результат вводит в заблуждение.                           |

## 2. Набор тест-кейсов

Эти критерии применяются ко всему набору ТК, который агент сгенерировал по требованиям.

Оценка показывает качество набора как целого, а не качество одного конкретного ТК.

### positive\_coverage - Позитивное покрытие

Проверяет, есть ли позитивные тест-кейсы для требований, где позитивный сценарий нужен.

score = требования с релевантным позитивным ТК / требования, где позитивный ТК нужен \* 10

| Оценка | Когда ставим                                                   |
|--------|----------------------------------------------------------------|
| 10     | Все применимые требования покрыты релевантными позитивными ТК. |
| 9      | Почти все покрыто, есть единичный minor-пропуск.               |
| 8      | Покрытие хорошее, но есть несколько неключевых пропусков.      |

| Оценка | Когда ставим                                                  |
|--------|---------------------------------------------------------------|
| 7      | Основная часть требований покрыта, но есть заметные пропуски. |
| 6      | Позитивные ТК есть, но часть важных требований не покрыта.    |
| 5      | Покрыто около половины применимых требований.                 |
| 4      | Позитивные сценарии есть выборочно и не закрывают скоуп.      |
| 3      | Покрыты только единичные позитивные сценарии.                 |
| 2      | Есть 1-2 слабых позитивных ТК без уверенного покрытия.        |
| 1      | Есть один нерепрезентативный позитивный сценарий.             |
| 0      | Позитивные ТК отсутствуют там, где они нужны.                 |

## negative\_coverage - Негативное покрытие

Проверяет, есть ли негативные тест-кейсы там, где требование подразумевает ошибки, запреты, ограничения или альтернативное поведение.

score = требования с релевантным негативным ТК / требования, где негативный ТК нужен \* 10

| Оценка | Когда ставим                                                         |
|--------|----------------------------------------------------------------------|
| 10     | Все применимые требования покрыты релевантными негативными ТК.       |
| 9      | Почти все покрыто, есть единичный minor-пропуск.                     |
| 8      | Негативное покрытие хорошее, но есть несколько неключевых пропусков. |
| 7      | Основные негативные риски покрыты, но часть проверок отсутствует.    |
| 6      | Негативные проверки есть, но часть важных рисков не закрыта.         |
| 5      | Покрыто около половины применимых негативных сценариев.              |
| 4      | Негативные сценарии есть выборочно и не закрывают основные риски.    |
| 3      | Есть единичные негативные сценарии без системного покрытия.          |
| 2      | Есть 1-2 слабых негативных ТК, релевантность спорная.                |
| 1      | Есть один нерепрезентативный негативный сценарий.                    |
| 0      | Негативные ТК отсутствуют там, где они нужны.                        |

## suite\_cleanliness - Чистота набора

Проверяет, нет ли в наборе лишних, нерелевантных, дублирующих или галлюцинированных ТК.

| Оценка | Когда ставим                                                            |
|--------|-------------------------------------------------------------------------|
| 10     | В наборе нет лишних, нерелевантных и дублирующих ТК.                    |
| 9      | Есть единичный minor-дубль или спорный ТК без влияния на итог.          |
| 8      | Есть несколько minor-дублей или спорных ТК, набор остается чистым.      |
| 7      | Есть заметные дубли или спорные ТК, но набор в целом полезен.           |
| 6      | Загрязнение заметно и требует ручной чистки, но основа набора пригодна. |
| 5      | Примерно половина набора полезна, остальное требует фильтрации.         |
| 4      | Лишние или дублирующие ТК существенно загрязняют набор.                 |
| 3      | Набор в основном раздут дублями или нерелевантными сценариями.          |
| 2      | Полезные ТК есть единично, большая часть набора шумовая.                |
| 1      | Почти весь набор нерелевантен или дублирует один и тот же смысл.        |
| 0      | Набор непригоден из-за лишних, дублирующих или нерелевантных ТК.        |

## required\_checks\_coverage - Покрытие обязательных проверок

Проверяет, покрыты ли обязательные проверки из требований или эталонного набора.

score = покрытые обязательные проверки / обязательные проверки всего \* 10

| Оценка | Когда ставим                                                             |
|--------|--------------------------------------------------------------------------|
| 10     | Все обязательные проверки покрыты.                                       |
| 9      | Пропущена одна minor-проверка или есть небольшая спорность трассировки.  |
| 8      | Почти все обязательные проверки покрыты, есть несколько minor-пропусков. |
| 7      | Основная часть обязательных проверок покрыта.                            |
| 6      | Покрыта значимая часть, но есть важные пропуски.                         |
| 5      | Покрыто около половины обязательных проверок.                            |
| 4      | Покрыты отдельные проверки, но есть существенные пропуски.               |
| 3      | Большинство обязательных проверок пропущено.                             |
| 2      | Есть 1-2 обязательные проверки, но системного покрытия нет.              |
| 1      | Есть один слабый признак покрытия обязательной проверки.                 |
| 0      | Обязательные проверки не покрыты.                                        |

## overall\_completeness - Общая полнота набора

Проверяет, достаточен ли набор ТК для проверяемого скоупа в целом.

В MVP это итоговая экспертная оценка, которая учитывает позитивное покрытие, негативное покрытие, обязательные проверки, чистоту набора и пригодность результата.

| Оценка | Когда ставим                                                                              |
|--------|-------------------------------------------------------------------------------------------|
| 10     | Набор достаточен для скоупа и закрывает основные ожидаемые сценарии без ручной доработки. |
| 9      | Набор почти готов, нужны только minor-уточнения.                                          |
| 8      | Набор хороший, пригоден после небольшой ручной проверки.                                  |
| 7      | Набор покрывает основу, но требует заметной доработки.                                    |
| 6      | Набор можно использовать только как черновик для ручной переработки.                      |
| 5      | Набор частично полезен, но недостаточен для уверенной проверки.                           |
| 4      | Набор недостаточен, есть только отдельные полезные сценарии.                              |
| 3      | Набор почти не закрывает проверяемый скоуп.                                               |
| 2      | Есть единичные полезные элементы без целостного покрытия.                                 |
| 1      | Набор практически непригоден, но содержит один слабый полезный фрагмент.                  |
| 0      | Набор отсутствует или полностью непригоден.                                               |

## 3. Отдельный тест-кейс

Эти критерии применяются к каждому отдельному ТК.

В итоговом отчете по раунду может выводиться среднее значение по всем ТК.

## classification\_correctness - Корректность вида ТК

Проверяет, правильно ли определен вид ТК: UI, API, интеграционный, E2E или другой применимый тип.

| Оценка | Когда ставим                                                                    |
|--------|---------------------------------------------------------------------------------|
| 10     | Вид ТК полностью соответствует названию, меткам, шагам и ожидаемым результатам. |
| 9      | Вид корректен, есть единичная minor-спорность.                                  |
| 8      | Вид в целом корректен, но есть несколько спорных признаков.                     |
| 7      | Вид вероятно корректен, но требует ручного подтверждения.                       |
| 6      | Вид частично соответствует сценарию, но классификация нестабильна.              |
| 5      | Вид подходит примерно наполовину или смешивает несколько типов.                 |
| 4      | Вид слабо соответствует фактическому сценарию.                                  |
| 3      | Вид скорее неверный, но есть отдельные совпадающие признаки.                    |
| 2      | Вид почти полностью неверный.                                                   |

| Оценка | Когда ставим                                                           |
|--------|------------------------------------------------------------------------|
| 1      | Есть один слабый признак выбранного вида, но классификация непригодна. |
| 0      | Вид отсутствует или полностью неверен.                                 |

## template\_required\_attributes - Шаблон и обязательные атрибуты

Проверяет, соответствует ли ТК шаблону и заполнены ли обязательные атрибуты: ссылка на задачу, ссылка на требования/источник, тип, направление, заголовок и другие обязательные поля.

score = заполненные обязательные атрибуты / обязательные атрибуты всего \* 10

| Оценка | Когда ставим                                                       |
|--------|--------------------------------------------------------------------|
| 10     | Шаблон соблюден, все обязательные атрибуты заполнены.              |
| 9      | Есть один minor-пробел в атрибутах без влияния на использование.   |
| 8      | Шаблон почти соблюден, есть несколько небольших пробелов.          |
| 7      | Основная структура есть, но часть обязательных атрибутов неполная. |
| 6      | ТК читаем, но обязательные ссылки/поля заполнены заметно неполно.  |
| 5      | Шаблон соблюден примерно наполовину.                               |
| 4      | Шаблон или обязательные атрибуты существенно нарушены.             |
| 3      | Есть только отдельные элементы шаблона.                            |
| 2      | Атрибуты почти отсутствуют, структура плохо распознается.          |
| 1      | Есть один слабый элемент шаблона.                                  |
| 0      | Шаблон и обязательные атрибуты отсутствуют.                        |

## conditions\_quality - Предусловия и постусловия

Проверяет, есть ли у ТК корректные предусловия и постусловия, и не записаны ли постусловия как шаги сценария.

| Оценка | Когда ставим                                                                      |
|--------|-----------------------------------------------------------------------------------|
| 10     | Предусловия и постусловия корректно описаны, проверяемы и соответствуют сценарию. |
| 9      | Условия корректны, есть единичная minor-неточность.                               |
| 8      | В целом корректны, но есть небольшие пробелы или неполнота.                       |
| 7      | Основной контекст задан, но часть условий требует уточнения.                      |
| 6      | Условия частичные, но сценарий еще можно выполнить.                               |
| 5      | Предусловия/постусловия описаны примерно наполовину.                              |
| 4      | Условия неполные, спорные или плохо связаны со сценарием.                         |
| 3      | Условия почти потеряны или сформулированы как шаги.                               |
| 2      | Есть единичные слабые условия без достаточного контекста.                         |
| 1      | Есть один слабый признак условия.                                                 |
| 0      | Необходимые предусловия и постусловия отсутствуют.                                |

## step\_atomicity - Атомарность шагов

Проверяет, что каждый шаг содержит одно действие или одну проверяемую операцию.

score = атомарные шаги / шаги всего \* 10

| Оценка | Когда ставим                                                     |
|--------|------------------------------------------------------------------|
| 10     | Каждый шаг содержит одно действие или одну проверяемую операцию. |
| 9      | Есть единичная minor-склейка без влияния на выполнение.          |
| 8      | Шаги почти атомарны, есть несколько небольших склеек.            |
| 7      | Основная часть шагов атомарна, но часть требует переразбиения.   |
| 6      | Часть шагов смешивает несколько действий, сценарий еще понятен.  |
| 5      | Примерно половина шагов неатомарна.                              |

| Оценка | Когда ставим                                                |
|--------|-------------------------------------------------------------|
| 4      | Много шагов объединяют разные действия или проверки.        |
| 3      | Шаги в основном неатомарны и требуют переразбиения.         |
| 2      | Есть единичные атомарные шаги, структура почти непригодна.  |
| 1      | Есть один слабый атомарный фрагмент.                        |
| 0      | Шаги отсутствуют или не являются шагами тестового сценария. |

## expected\_result\_quality - Ожидаемый результат

Проверяет, что у каждого шага есть конкретный, проверяемый и соответствующий шагу ожидаемый результат.

$\text{score} = \text{шаги с корректным ожидаемым результатом} / \text{шаги всего} * 10$

| Оценка | Когда ставим                                                                                |
|--------|---------------------------------------------------------------------------------------------|
| 10     | У каждого шага есть конкретный, проверяемый и соответствующий действию ожидаемый результат. |
| 9      | Есть единичная minor-неточность в ожидаемом результате.                                     |
| 8      | Ожидаемые результаты почти все корректны, есть несколько неточностей.                       |
| 7      | Основной сценарий проверяем, но часть ожидаемых результатов неполная.                       |
| 6      | Ожидаемые результаты частичные, но ключевые проверки остаются понятными.                    |
| 5      | Около половины ожидаемых результатов неполные или спорные.                                  |
| 4      | Ожидаемые результаты часто общие, непроверяемые или плохо связаны с шагами.                 |
| 3      | Ожидаемые результаты почти отсутствуют или часто не соответствуют действиям.                |
| 2      | Есть единичные слабые ожидаемые результаты.                                                 |
| 1      | Есть один слабый ожидаемый результат без достаточной проверяемости.                         |
| 0      | Ожидаемые результаты отсутствуют.                                                           |

## no\_hallucinations - Достоверность / отсутствие галлюцинаций

Проверяет, что ТК не содержит фактов, деталей, UI-элементов, ролей, API, статусов, endpoint-ов или ограничений, которых нет в требованиях и источниках.

| Оценка | Когда ставим                                                          |
|--------|-----------------------------------------------------------------------|
| 10     | Неподтвержденных фактов нет.                                          |
| 9      | Есть единичная minor-деталь с низким риском неподтвержденности.       |
| 8      | Есть несколько minor-деталей, но они не меняют смысл проверки.        |
| 7      | Есть отдельные неподтвержденные факты, требуется ревью.               |
| 6      | Неподтвержденные детали заметны, но основной сценарий еще релевантен. |
| 5      | Неподтвержденные факты существенно влияют на корректность части ТК.   |
| 4      | Неподтвержденные факты заметно искажают сценарий.                     |
| 3      | ТК в основном построен на неподтвержденных деталях.                   |
| 2      | Почти весь ТК основан на выдуманном или неподтвержденном поведении.   |
| 1      | Есть один слабый релевантный элемент, остальное недостоверно.         |
| 0      | ТК непригоден из-за галлюцинаций.                                     |

## Как читать итоговую оценку в отчете

Для набора ТК оценка обычно выставляется один раз на весь набор.

Для отдельных ТК оценка выставляется каждому тест-кейсу отдельно, а в итоговом отчете по раунду выводится среднее значение по всем ТК:

$\text{score\_in\_report} = \text{среднее значение оценок по всем ТК по выбранному критерию}$

Например, если по критерию **expected\_result\_quality** часть ТК получила **10**, часть **8**, а часть **6**, итоговая оценка в отчете может быть **8.5/10**.

## Почему оценка может быть дробной

Дробная оценка нужна в двух случаях.

Первый случай - оценка рассчитана по доле покрытия:

13 покрытых обязательных проверок / 20 обязательных проверок \* 10 = 6.5

Второй случай - экспертная оценка находится между двумя уровнями шкалы.

Например:

6 = основная часть покрыта, но пропуски существенные

7 = основная часть покрыта, пропуски уже умеренные

6.5 = ситуация между этими состояниями

Таким образом, **6.5** - это не случайная оценка, а способ показать промежуточное качество между двумя описанными уровнями.