

Методика выставления оценок

Документ описывает, как выставять оценки по шкале **0..10** в MVP eval-процесса.

Оценка хранится как **REAL**, поэтому допустимы целые и дробные значения.

Общая шкала

Оценка	Общая интерпретация
10	Эталон: критерий выполнен полностью, замечаний нет.
9	Почти эталон: есть единичные minor-замечания без влияния на итог.
8	Хорошо: результат пригоден, но есть несколько небольших замечаний.
7	Приемлемо: основная польза есть, но есть заметные пропуски.
6	Нижняя граница приемлемого: результат можно использовать только после доработки.
5	Слабо: критерий выполнен примерно наполовину или сильно нестабилен.
4	Плохо: есть отдельные полезные элементы, но качество мешает использовать результат.
3	Очень плохо: выполнены только единичные элементы критерия.
2	Почти отсутствует: есть следы выполнения, но практической пользы почти нет.
1	Минимальное соответствие: найден один слабый признак выполнения критерия.
0	Критерий не выполнен или сущность отсутствует.

Профиль датасета и значение 10/10

Оценка всегда выставляется относительно профиля входных данных (**dataset_cases.input_profile_code**), а не только относительно идеального gold-датасета.

Примеры профилей:

- **customer_gold_requirements** - эталон заказчика, ожидаем максимальное совпадение с gold requirements и gold test cases;
- **complete_technical_docs** - полная техдокументация, ожидаем полное покрытие;
- **incomplete_fragmented_docs** - неполная документация, ожидаем безопасное частичное покрытие без додумывания;
- **business_user_story_docs** - бизнес-документация, ожидаем покрытие проверяемого бизнес-ядра;
- **conflicting_noisy_docs** - шумная/противоречивая документация, ожидаем фильтрацию шума и явную фиксацию конфликтов;
- **abstract_high_level_docs** - верхнеуровневая документация, ожидаем покрытие проверяемого ядра и явное указание пробелов.

Поэтому для плохих или неполных требований высокий балл возможен, если агент корректно отработал ограничения входа.

Например, по неполной документации **10/10** не означает "сгенерированы все возможные ТК как по полной ТЗ". Это означает:

- покрыты все явно выводимые сценарии;
- непокрытые зоны объяснены нехваткой данных;
- агент не добавил неподтвержденные роли, API, UI, статусы или бизнес-правила;
- противоречия и пробелы не замаскированы как уверенные требования.

Цель критерия выбирается в таком порядке:

1. **dataset_case_criterion_targets** - если для конкретного dataset case задана частная цель;
2. **dataset_profile_criterion_targets** - если есть цель для **input_profile_code**;
3. базовая цель из таблицы критерия.

1. Сгенерированные требования / декомпозиция

Эти критерии применяются к требованиям, которые агент получил после декомпозиции исходного материала.

Сравнение идет с эталонными атомарными требованиями.

decomposition_completeness - Полнота декомпозиции

Проверяет, все ли значимые атомарные требования из эталона были выделены агентом.

Основной расчет:

$\text{score} = \text{найденные значимые атомарные требования} / \text{эталонные атомарные требования} * 10$

Оценка снижается, если требование формально найдено, но искажено по смыслу.

Оценка	Когда ставим
10	Все значимые атомарные требования выделены, потерь и смысловых искажений нет.
9	Пропущена только незначительная деталь, на генерацию ТК почти не влияет.
8	Есть 1-2 minor-пропуска, основные требования сохранены.
7	Выделена основная часть требований, но есть заметные пропуски.
6	Основа сохранена, но пропущено несколько важных ограничений или условий.
5	Выделено около половины полезного содержания.
4	Потеряна существенная часть требований, результат требует почти полной ручной доработки.
3	Найдены только отдельные требования, большая часть смысла потеряна.
2	Есть единичные фрагменты требований без полноценной декомпозиции.
1	Есть один слабый признак исходного требования, но результат почти непригоден.
0	Декомпозиция отсутствует или не отражает входное требование.

decomposition_boundaries - Границы требований

Проверяет, корректно ли агент нарезал требования: не склеил независимые требования и не раздробил одно требование на бессмысленные части.

При наличии точной разметки:

$\text{score} = \text{требования с корректными границами} / \text{проверенные требования} * 10$

Если точной разметки нет, используется экспертная оценка.

Оценка	Когда ставим
10	Все требования выделены самостоятельными проверяемыми единицами.
9	Есть единичное спорное разделение или объединение без влияния на проверяемость.
8	Есть несколько minor-спорных границ, но структура в целом корректна.
7	Большая часть границ корректна, но есть заметные склейки или лишнее дробление.
6	Границы частично корректны, но часть требований неудобна для генерации ТК.
5	Примерно половина требований нарезана спорно.
4	Границы часто нарушены: независимые требования склеены или атомарность потеряна.
3	Большая часть результата состоит из некорректных или несамостоятельных фрагментов.
2	Есть отдельные попытки нарезки, но они почти не помогают проверке.
1	Границы почти не определены, есть только случайные фрагменты.
0	Границы не определены или декомпозиция непригодна.

requirement_consolidation - Консолидация требований

Проверяет, корректно ли агент объединяет одинаковую или связанную информацию из разных источников: без дублей, противоречий и потери смысла.

При наличии точной разметки:

$\text{score} = \text{корректно объединенные связи} / \text{связки, которые нужно было объединить} * 10$

Оценка	Когда ставим
10	Связанная информация объединена корректно, дублей и противоречий нет.
9	Есть единичный minor-дубль или minor-потеря контекста.
8	Консолидация в целом корректна, но есть несколько небольших дублей.
7	Большая часть связанной информации объединена, но часть требует ревью.
6	Есть полезная консолидация, но заметны дубли или потеря связей.
5	Консолидация выполнена примерно наполовину.
4	Есть заметные дубли, несогласованные формулировки или потеря связей между источниками.
3	Агент почти не консолидирует связанные требования и плодит дубли.
2	Есть единичная попытка объединения, но она почти не помогает.
1	Консолидация случайная и практически непригодная.
0	Консолидация отсутствует или результат вводит в заблуждение.

2. Набор тест-кейсов

Эти критерии применяются ко всему набору ТК, который агент сгенерировал по требованиям.

Оценка показывает качество набора как целого, а не качество одного конкретного ТК.

positive_coverage - Позитивное покрытие

Проверяет, есть ли позитивные тест-кейсы для требований, где позитивный сценарий нужен.

score = требования с релевантным позитивным ТК / требования, где позитивный ТК нужен * 10

Оценка	Когда ставим
10	Все применимые требования покрыты релевантными позитивными ТК.
9	Почти все покрыто, есть единичный minor-пропуск.
8	Покрытие хорошее, но есть несколько неключевых пропусков.
7	Основная часть требований покрыта, но есть заметные пропуски.
6	Позитивные ТК есть, но часть важных требований не покрыта.
5	Покрыто около половины применимых требований.
4	Позитивные сценарии есть выборочно и не закрывают скоуп.
3	Покрыты только единичные позитивные сценарии.
2	Есть 1-2 слабых позитивных ТК без уверенного покрытия.
1	Есть один нерепрезентативный позитивный сценарий.
0	Позитивные ТК отсутствуют там, где они нужны.

negative_coverage - Негативное покрытие

Проверяет, есть ли негативные тест-кейсы там, где требование подразумевает ошибки, запреты, ограничения или альтернативное поведение.

score = требования с релевантным негативным ТК / требования, где негативный ТК нужен * 10

Оценка	Когда ставим
10	Все применимые требования покрыты релевантными негативными ТК.
9	Почти все покрыто, есть единичный minor-пропуск.
8	Негативное покрытие хорошее, но есть несколько неключевых пропусков.
7	Основные негативные риски покрыты, но часть проверок отсутствует.
6	Негативные проверки есть, но часть важных рисков не закрыта.
5	Покрыто около половины применимых негативных сценариев.
4	Негативные сценарии есть выборочно и не закрывают основные риски.
3	Есть единичные негативные сценарии без системного покрытия.

Оценка	Когда ставим
2	Есть 1-2 слабых негативных ТК, релевантность спорная.
1	Есть один нерепрезентативный негативный сценарий.
0	Негативные ТК отсутствуют там, где они нужны.

suite_cleanliness - Чистота набора

Проверяет, нет ли в наборе лишних, нерелевантных, дублирующих или галлюцинированных ТК.

Оценка	Когда ставим
10	В наборе нет лишних, нерелевантных и дублирующих ТК.
9	Есть единственный minor-дубль или спорный ТК без влияния на итог.
8	Есть несколько minor-дублей или спорных ТК, набор остается чистым.
7	Есть заметные дубли или спорные ТК, но набор в целом полезен.
6	Загрязнение заметно и требует ручной чистки, но основа набора пригодна.
5	Примерно половина набора полезна, остальное требует фильтрации.
4	Лишние или дублирующие ТК существенно загрязняют набор.
3	Набор в основном раздут дублями или нерелевантными сценариями.
2	Полезные ТК есть единично, большая часть набора шумовая.
1	Почти весь набор нерелевантен или дублирует один и тот же смысл.
0	Набор непригоден из-за лишних, дублирующих или нерелевантных ТК.

required_checks_coverage - Покрытие обязательных проверок

Проверяет, покрыты ли обязательные проверки из требований или эталонного набора.

$score = \text{покрытые обязательные проверки} / \text{обязательные проверки всего} * 10$

Оценка	Когда ставим
10	Все обязательные проверки покрыты.
9	Пропущена одна minor-проверка или есть небольшая спорность трассировки.
8	Почти все обязательные проверки покрыты, есть несколько minor-пропусков.
7	Основная часть обязательных проверок покрыта.
6	Покрыта значимая часть, но есть важные пропуски.
5	Покрыто около половины обязательных проверок.
4	Покрыты отдельные проверки, но есть существенные пропуски.
3	Большинство обязательных проверок пропущено.
2	Есть 1-2 обязательные проверки, но системного покрытия нет.
1	Есть один слабый признак покрытия обязательной проверки.
0	Обязательные проверки не покрыты.

overall_completeness - Общая полнота набора

Проверяет, достаточен ли набор ТК для проверяемого скоупа в целом.

В MVP это итоговая экспертная оценка, которая учитывает позитивное покрытие, негативное покрытие, обязательные проверки, чистоту набора и пригодность результата.

Оценка	Когда ставим
10	Набор достаточен для скоупа и закрывает основные ожидаемые сценарии без ручной доработки.
9	Набор почти готов, нужны только minor-уточнения.
8	Набор хороший, пригоден после небольшой ручной проверки.
7	Набор покрывает основу, но требует заметной доработки.

Оценка	Когда ставим
6	Набор можно использовать только как черновик для ручной переработки.
5	Набор частично полезен, но недостаточен для уверенной проверки.
4	Набор недостаточен, есть только отдельные полезные сценарии.
3	Набор почти не закрывает проверяемый скоуп.
2	Есть единичные полезные элементы без целостного покрытия.
1	Набор практически непригоден, но содержит один слабый полезный фрагмент.
0	Набор отсутствует или полностью непригоден.

3. Отдельный тест-кейс

Эти критерии применяются к каждому отдельному ТК.

В итоговом отчете по раунду может выводиться среднее значение по всем ТК.

classification_correctness - Корректность вида ТК

Проверяет, правильно ли определен вид ТК: UI, API, интеграционный, E2E или другой применимый тип.

Оценка	Когда ставим
10	Вид ТК полностью соответствует названию, меткам, шагам и ожидаемым результатам.
9	Вид корректен, есть единичная minor-спорность.
8	Вид в целом корректен, но есть несколько спорных признаков.
7	Вид вероятно корректен, но требует ручного подтверждения.
6	Вид частично соответствует сценарию, но классификация нестабильна.
5	Вид подходит примерно наполовину или смешивает несколько типов.
4	Вид слабо соответствует фактическому сценарию.
3	Вид скорее неверный, но есть отдельные совпадающие признаки.
2	Вид почти полностью неверный.
1	Есть один слабый признак выбранного вида, но классификация непригодна.
0	Вид отсутствует или полностью неверен.

template_required_attributes - Шаблон и обязательные атрибуты

Проверяет, соответствует ли ТК шаблону и заполнены ли обязательные атрибуты: ссылка на задачу, ссылка на требования/источник, тип, направление, заголовок и другие обязательные поля.

$\text{score} = \frac{\text{заполненные обязательные атрибуты}}{\text{обязательные атрибуты всего}} * 10$

Оценка	Когда ставим
10	Шаблон соблюден, все обязательные атрибуты заполнены.
9	Есть один minor-пробел в атрибутах без влияния на использование.
8	Шаблон почти соблюден, есть несколько небольших пробелов.
7	Основная структура есть, но часть обязательных атрибутов неполная.
6	ТК читаем, но обязательные ссылки/поля заполнены заметно неполно.
5	Шаблон соблюден примерно наполовину.
4	Шаблон или обязательные атрибуты существенно нарушены.
3	Есть только отдельные элементы шаблона.
2	Атрибуты почти отсутствуют, структура плохо распознается.
1	Есть один слабый элемент шаблона.
0	Шаблон и обязательные атрибуты отсутствуют.

conditions_quality - Предусловия и постусловия

Проверяет, есть ли у ТК корректные предусловия и постусловия, и не записаны ли постусловия как шаги сценария.

Оценка	Когда ставим
10	Предусловия и постусловия корректно описаны, проверяемы и соответствуют сценарию.
9	Условия корректны, есть единичная minor-неточность.
8	В целом корректны, но есть небольшие пробелы или неполнота.
7	Основной контекст задан, но часть условий требует уточнения.
6	Условия частичные, но сценарий еще можно выполнить.
5	Предусловия/постусловия описаны примерно наполовину.
4	Условия неполные, спорные или плохо связаны со сценарием.
3	Условия почти потеряны или сформулированы как шаги.
2	Есть единичные слабые условия без достаточного контекста.
1	Есть один слабый признак условия.
0	Необходимые предусловия и постусловия отсутствуют.

step_atomicity - Атомарность шагов

Проверяет, что каждый шаг содержит одно действие или одну проверяемую операцию.

$\text{score} = \text{атомарные шаги} / \text{шаги всего} * 10$

Оценка	Когда ставим
10	Каждый шаг содержит одно действие или одну проверяемую операцию.
9	Есть единичная minor-склейка без влияния на выполнение.
8	Шаги почти атомарны, есть несколько небольших склеек.
7	Основная часть шагов атомарна, но часть требует переразбиения.
6	Часть шагов смешивает несколько действий, сценарий еще понятен.
5	Примерно половина шагов неатомарна.
4	Много шагов объединяют разные действия или проверки.
3	Шаги в основном неатомарны и требуют переразбиения.
2	Есть единичные атомарные шаги, структура почти непригодна.
1	Есть один слабый атомарный фрагмент.
0	Шаги отсутствуют или не являются шагами тестового сценария.

expected_result_quality - Ожидаемый результат

Проверяет, что у каждого шага есть конкретный, проверяемый и соответствующий шагу ожидаемый результат.

$\text{score} = \text{шаги с корректным ожидаемым результатом} / \text{шаги всего} * 10$

Оценка	Когда ставим
10	У каждого шага есть конкретный, проверяемый и соответствующий действию ожидаемый результат.
9	Есть единичная minor-неточность в ожидаемом результате.
8	Ожидаемые результаты почти все корректны, есть несколько неточностей.
7	Основной сценарий проверяем, но часть ожидаемых результатов неполная.
6	Ожидаемые результаты частичные, но ключевые проверки остаются понятными.
5	Около половины ожидаемых результатов неполные или спорные.
4	Ожидаемые результаты часто общие, непроверяемые или плохо связаны с шагами.
3	Ожидаемые результаты почти отсутствуют или часто не соответствуют действиям.
2	Есть единичные слабые ожидаемые результаты.
1	Есть один слабый ожидаемый результат без достаточной проверяемости.
0	Ожидаемые результаты отсутствуют.

no_hallucinations - Достоверность / отсутствие галлюцинаций

Проверяет, что ТК не содержит фактов, деталей, UI-элементов, ролей, API, статусов, endpoint-ов или ограничений, которых нет в требованиях и источниках.

Оценка	Когда ставим
10	Неподтвержденных фактов нет.
9	Есть единичная mпог-деталь с низким риском неподтвержденности.
8	Есть несколько mпог-деталей, но они не меняют смысл проверки.
7	Есть отдельные неподтвержденные факты, требуется ревью.
6	Неподтвержденные детали заметны, но основной сценарий еще релевантен.
5	Неподтвержденные факты существенно влияют на корректность части ТК.
4	Неподтвержденные факты заметно искажают сценарий.
3	ТК в основном построен на неподтвержденных деталях.
2	Почти весь ТК основан на выдуманном или неподтвержденном поведении.
1	Есть один слабый релевантный элемент, остальное недостоверно.
0	ТК непригоден из-за галлюцинаций.

Как читать итоговую оценку в отчете

Для набора ТК оценка обычно выставляется один раз на весь набор.

Для отдельных ТК оценка выставляется каждому тест-кейсу отдельно, а в итоговом отчете по раунду выводится среднее значение по всем ТК:

`score_in_report` = среднее значение оценок по всем ТК по выбранному критерию

Например, если по критерию **expected_result_quality** часть ТК получила **10**, часть **8**, а часть **6**, итоговая оценка в отчете может быть **8.5/10**.

Почему оценка может быть дробной

Дробная оценка нужна в двух случаях.

Первый случай - оценка рассчитана по доле покрытия:

$13 \text{ покрытых обязательных проверок} / 20 \text{ обязательных проверок} * 10 = 6.5$

Второй случай - экспертная оценка находится между двумя уровнями шкалы.

Например:

6 = основная часть покрыта, но пропуски существенные
7 = основная часть покрыта, пропуски уже умеренные
6.5 = ситуация между этими состояниями

Таким образом, **6.5** - это не случайная оценка, а способ показать промежуточное качество между двумя описанными уровнями.