

Методика выставления оценок

Документ описывает, как интерпретировать оценки по шкале **0..10** в MVP eval-процесса.

Оценка хранится как **REAL**, поэтому допустимы как целые, так и дробные значения.

Общая шкала

Оценка	Интерпретация
10	Эталон: критерий выполнен полностью, замечаний нет.
8-9	Почти эталон: есть небольшие замечания, но они не ломают результат.
6-7	Частично хорошо: основная польза есть, но есть заметные пропуски или спорные места.
4-5	Слабо: критерий выполнен фрагментарно, качество заметно мешает использовать результат.
1-3	Плохо: результат почти не соответствует критерию.
0	Критерий не выполнен или сущность отсутствует.

1. Сгенерированные требования / декомпозиция

Эти критерии применяются к требованиям, которые агент получил после декомпозиции исходного материала.

Сравнение идет с эталонными атомарными требованиями.

decomposition_completeness - Полнота декомпозиции

Проверяет, все ли значимые атомарные требования из эталона были выделены агентом.

Основной расчет:

$score = \text{найденные значимые атомарные требования} / \text{эталонные атомарные требования} * 10$

Оценка снижается, если требование формально найдено, но искажено по смыслу.

decomposition_boundaries - Границы требований

Проверяет, корректно ли агент нарезал требования: не склеил независимые требования и не раздробил одно требование на бессмысленные части.

При наличии точной разметки:

$score = \text{требования с корректными границами} / \text{проверенные требования} * 10$

Если точной разметки нет, используется экспертная оценка по общей шкале **0..10**.

requirement_consolidation - Консолидация требований

Проверяет, корректно ли агент объединяет одинаковую или связанную информацию из разных источников: без дублей, противоречий и потери смысла.

При наличии точной разметки:

$score = \text{корректно объединенные связи} / \text{связки, которые нужно было объединить} * 10$

Если связей между источниками нет, критерий может не измеряться или считаться выполненным для данного кейса.

2. Набор тест-кейсов

Эти критерии применяются ко всему набору ТК, который агент сгенерировал по требованиям.

Оценка показывает качество набора как целого, а не качество одного конкретного ТК.

positive_coverage - Позитивное покрытие

Проверяет, есть ли позитивные тест-кейсы для требований, где позитивный сценарий нужен.

$score = \text{требования с релевантным позитивным ТК} / \text{требования, где позитивный ТК нужен} * 10$

negative_coverage - Негативное покрытие

Проверяет, есть ли негативные тест-кейсы там, где требование подразумевает ошибки, запреты, ограничения или альтернативное поведение.

$score = \text{требования с релевантным негативным ТК} / \text{требования, где негативный ТК нужен} * 10$

suite_cleanliness - Чистота набора

Проверяет, нет ли в наборе лишних, нерелевантных, дублирующих или галлюцинированных ТК.

Для MVP используется экспертная оценка с учетом:

- количества дублей;
- количества лишних ТК;
- количества нерелевантных ТК;
- количества ТК с неподтвержденными деталями;
- влияния этих проблем на итоговую полезность набора.

required_checks_coverage - Покрытие обязательных проверок

Проверяет, покрыты ли обязательные проверки из требований или эталонного набора.

$score = \text{покрытые обязательные проверки} / \text{обязательные проверки всего} * 10$

overall_completeness - Общая полнота набора

Проверяет, достаточен ли набор ТК для проверяемого скоупа в целом.

В MVP это итоговая экспертная оценка, которая учитывает:

- позитивное покрытие;
- негативное покрытие;
- обязательные проверки;
- чистоту набора;
- наличие основных бизнес/API/UI/интеграционных сценариев;
- пригодность набора для ручной или автоматизированной проверки.

Это не всегда простое среднее арифметическое: один критичный пропуск может быть важнее нескольких мелких замечаний.

3. Отдельный тест-кейс

Эти критерии применяются к каждому отдельному ТК.

В итоговом отчете по раунду может выводиться среднее значение по всем ТК.

classification_correctness - Корректность вида ТК

Проверяет, правильно ли определен вид ТК: UI, API, интеграционный, E2E или другой применимый тип.

Оценка выставляется по соответствию типа названию, меткам, шагам и фактическому содержанию сценария.

template_required_attributes - Шаблон и обязательные атрибуты

Проверяет, соответствует ли ТК шаблону и заполнены ли обязательные атрибуты: ссылка на задачу, ссылка на требования/источник, тип, направление, заголовок и другие обязательные поля.

$score = \text{заполненные обязательные атрибуты} / \text{обязательные атрибуты всего} * 10$

Если структура ТК нарушена настолько, что атрибуты нельзя надежно выделить, оценка дополнительно снижается.

conditions_quality - Предусловия и постусловия

Проверяет, есть ли у ТК корректные предусловия и постусловия, и не записаны ли постусловия как шаги сценария.

Оценка учитывает полноту, проверяемость и связь условий с фактическим сценарием.

step_atomicity - Атомарность шагов

Проверяет, что каждый шаг содержит одно действие или одну проверяемую операцию.

$score = \text{атомарные шаги} / \text{шаги всего} * 10$

Если шаги формально атомарны, но сценарий из-за этого потерял смысл, оценка корректируется экспертно.

expected_result_quality - Ожидаемый результат

Проверяет, что у каждого шага есть конкретный, проверяемый и соответствующий шагу ожидаемый результат.

$score = \text{шаги с корректным ожидаемым результатом} / \text{шаги всего} * 10$

Ожидаемый результат считается некорректным, если он слишком общий, не проверяемый или не соответствует действию в шаге.

no_hallucinations - Достоверность / отсутствие галлюцинаций

Проверяет, что ТК не содержит фактов, деталей, UI-элементов, ролей, API, статусов, endpoint-ов или ограничений, которых нет в требованиях и источниках.

Для MVP используется экспертная оценка с учетом количества и серьезности неподтвержденных фактов.

Примеры факторов, снижающих оценку:

- мелкая неподтвержденная деталь без влияния на сценарий;
- спорная роль, поле, статус или UI-элемент;
- неподтвержденный endpoint, бизнес-правило или ограничение;
- тест-кейс построен на выдуманном поведении.

Как читать итоговую оценку в отчете

Для набора ТК оценка обычно выставляется один раз на весь набор.

Для отдельных ТК оценка выставляется каждому тест-кейсу отдельно, а в итоговом отчете по раунду выводится среднее значение по всем ТК:

$score_in_report = \text{среднее значение оценок по всем ТК по выбранному критерию}$

Например, если по критерию **expected_result_quality** часть ТК получила **10**, часть **8**, а часть **6**, итоговая оценка в отчете может быть **8.5/10**.

Почему оценка может быть дробной

Дробная оценка нужна в двух случаях.

Первый случай - оценка рассчитана по доле покрытия:

$13 \text{ покрытых обязательных проверок} / 20 \text{ обязательных проверок} * 10 = 6.5$

Второй случай - экспертная оценка находится между двумя уровнями шкалы.

Например:

6 = основная часть покрыта, но пропуски существенные

7 = основная часть покрыта, пропуски уже умеренные

6.5 = ситуация между этими состояниями

Таким образом, **6.5** - это не случайная оценка, а способ показать промежуточное качество между двумя описанными уровнями.